

Smart Artificial Review Assistance (SARA)

Abschlussbericht

Datum
01.12.2025

Autoren: Dominik Kunz / Dominique Truninger

Inhaltsverzeichnis

1	Einleitung	2
1.1	Hintergrund und Kontext des Projekts	2
1.2	Projektkontext und Zielsetzung	2
1.3	Funktionsweise der Software SARA	2
2	Methodisches Vorgehen	3
2.1	Evaluationsdesign und Datengrundlage	3
2.1.1	Statistische Analyseverfahren	3
2.2	Durchführung der Usability-Testings	4
2.2.1	Teilnehmergruppen	5
2.2.2	Durchführung und Ergebnisse	5
3	Ergebnisse	5
3.1	Retest-Reliabilität	5
3.1.1	Ergebnisse des Systematic Reviews (Projekt DHL)	5
3.1.2	Ergebnisse des Scoping Reviews (Projekt DHEM)	6
3.1.3	Zusammenfassende Bewertung der Retest-Reliabilität	6
3.2	Interrater-Reliabilität	6
3.2.1	Analyse der Kontingenztafel	6
3.2.2	Statistische Kennwerte	7
3.2.3	Zusammenfassende Bewertung der Interrater-Reliabilität	7
3.3	Usability-Testing	7
3.3.1	Usability-Testing mit der Forschungsgruppe	7
3.3.2	Usability-Testing mit AI-Expertin	8
3.3.3	Usability-Testing mit einer Gruppe von Hochschulbibliothekarinnen	9
4	Diskussion	9
4.1	Herausforderung Sensitivität	9
4.2	Technische Stabilität und Usability	10
4.3	Diskussion der Implikationen der Ergebnisse aus den Usability Testings	10
5	Ausblick	10
6	Literaturverzeichnis	12

1 Einleitung

1.1 Hintergrund und Kontext des Projekts

Systematische Literaturreviews bilden das Fundament evidenzbasierter Wissenschaft. Sie sind essenziell, um den aktuellen Forschungsstand zu synthetisieren und Wissenslücken zu identifizieren. Die Durchführung solcher Reviews ist jedoch mit einem enormen Ressourcenaufwand verbunden. Insbesondere das initiale Screening von oft Tausenden von Titeln und Abstracts ("Title and Abstract Screening") bindet hochqualifiziertes wissenschaftliches Personal über Tage oder sogar Wochen. Angesichts der exponentiell wachsenden Menge an wissenschaftlichen Publikationen wird dieser manuelle Prozess zunehmend zum Flaschenhals, der Forschungsprojekte verlangsamt und erhebliche Kosten verursacht.

Vor diesem Hintergrund entstand das Projekt SARA, was für "Smart Artificial Review Assistant" steht. Ziel des Vorhabens ist es, diesen ressourcenintensiven Arbeitsschritt durch den Einsatz moderner künstlicher Intelligenz teilweise zu automatisieren, indem man den Double Screening Ansatz mittels einer digitalen Assistenz vereinfacht, ohne dabei die wissenschaftliche Sorgfalt zu kompromittieren.

1.2 Projektkontext und Zielsetzung

Das Projekt SARA wurde im Rahmen des DFF-Forschungsprogramms (Digital Futures Fund) gefördert und als interdisziplinäre Kooperation zwischen dem Departement Life Sciences und Facility Management sowie dem Departement Gesundheit der ZHAW realisiert.

Das primäre Ziel ist die Entwicklung eines digitalen Peers: Eine Software, die Forschende beim Screening-Prozess unterstützt, indem sie autonom Titel und Abstracts analysiert und eine Vorauswahl trifft. Dabei adressiert SARA eine zentrale Schwäche vieler existierender KI-Tools: die mangelnde Transparenz. Während herkömmliche Lösungen oft als "Black Box" agieren, liegt der Fokus von SARA auf Nachvollziehbarkeit und Systematik. Die Software soll nicht nur entscheiden, ob eine Studie relevant ist, sondern diese Entscheidung auch explizit begründen. Damit wird der systematische Ansatz wissenschaftlicher Methodik gewahrt und die Akzeptanz in der Forschungspraxis erhöht.

1.3 Funktionsweise der Software SARA

SARA fungiert als intelligenter Assistent, der den zeitaufwendigen Prozess der Studienselektion bei einem Double Screening teilweise automatisiert und somit die Arbeitszeit halbieren soll. Der Workflow folgt dabei einem klaren dreistufigen Prinzip:

1. **Input (Datenimport):** Die Software verarbeitet standardisierte bibliografische Formate (RIS, BibTeX) aus gängigen Datenbanken (z.B. PubMed, IEEE Xplore). Dabei werden relevante Metadaten wie Titel, Abstract, Autoren, Jahr, DOI, etc. extrahiert. Die Daten werden auf einer externen Datenbank abgelegt.
2. **Verarbeitung (KI-Screening):** Im Kern der Anwendung arbeiten Large Language Models (LLMs), auf welche mittels API zugegriffen werden kann. Für jeden einzelnen Datensatz (Titel und Abstract einer Studie) generiert SARA einen spezifischen Prompt, der die Rolle eines Fachexperten simuliert und den Abstract gegen die vom Nutzer definierten Ein- und Ausschlusskriterien prüft. Das Modell analysiert den Text semantisch und trifft eine Klassifikationsentscheidung.

3. **Output (Ergebnis):** Das Ergebnis ist eine angereicherte Datentabelle. Jede Studie erhält ein Label (Include/Exclude) sowie eine textuelle Begründung ("Reasoning"), warum diese Entscheidung getroffen wurde. Diese Ergebnisse können exportiert und nahtlos in den weiteren Forschungsprozess integriert werden.

Technisch basiert die Anwendung auf Python und nutzt das Framework Streamlit für eine intuitive Benutzeroberfläche. Die Architektur ist flexibel gestaltet und bindet LLMs über API-Schnittstellen an.

2 Methodisches Vorgehen

Um die Leistungsfähigkeit von SARA objektiv zu bewerten, wurde die Software in diesem Projekt einer Evaluation unterzogen. Für die Tests wurde das Modell GPT-4o von OpenAI verwendet, da dieses Modell in vergangenen Arbeiten verwendet wurde und der Prompt auf der Studie von Cao et al. (2024) aufbaut.

Die Qualitätssicherung erfolgte anhand der wissenschaftlichen Gütekriterien Reliabilität (Liefert die Software bei Wiederholung gleiche Ergebnisse?) und Validität (Stimmen die Ergebnisse mit denen menschlicher Experten überein?). Hierfür wurden reale Datensätze aus aktuellen Forschungsprojekten herangezogen, um die Praxistauglichkeit unter realistischen Bedingungen zu überprüfen.

Gleichzeitig wurden Usertestings mit ausgewählten Nutzergruppen durchgeführt, um die Usability und das Design der Software besser zu verstehen.

2.1 Evaluationsdesign und Datengrundlage

Die Leistungsfähigkeit der entwickelten Software SARA wurde anhand von zwei realen Datensätzen aus der Forschungspraxis getestet und evaluiert. Bei den zugrundeliegenden Literaturrecherchen handelte es sich um ein Systematic Review und ein Scoping Review von zwei unterschiedlichen Forschungsgruppen. Durch die Verwendung dieser zwei verschiedenen Review-Typen konnte die Leistungsfähigkeit der Software SARA unter variierenden Bedingungen und wissenschaftlichen Anforderungen getestet werden.

Zur Evaluierung der Softwarequalität wurden zwei Hauptdimensionen der Reliabilität untersucht:

1. **Retest-Reliabilität (Konsistenz):** Misst, ob die Software bei wiederholter Anwendung auf denselben Datensatz stabile Ergebnisse liefert.
2. **Interrater-Reliabilität (Validität):** Bewertet die Übereinstimmung zwischen den Entscheidungen der Software SARA (AI) und denen menschlicher Forschender (Human). Wobei die Ergebnisse der Forschenden als Goldstandard angesehen werden.

2.1.1 Statistische Analyseverfahren

Um die Ergebnisse quantifizierbar zu machen, wurden für beide Dimensionen spezifische statistische Kennwerte berechnet. Die Basis der Berechnungen bildete jeweils eine Kontingenztafel (Konfusionsmatrix), welche die Entscheidungen der KI (Include vs. Exclude) mit denen der Referenz (Wiederholter Durchlauf oder menschliche Entscheidung) in Beziehung setzt.

Metriken der Retest-Reliabilität

Für die Bestimmung der zeitlichen Stabilität der Software wurde **Cohen's Kappa** als primäres Mass verwendet. Im Gegensatz zur einfachen prozentualen Übereinstimmung korrigiert Cohen's Kappa die Übereinstimmung um den Zufallswert. Dies ist bei Literaturreviews essenziell, da die Mehrheit der Artikel in der Regel ausgeschlossen wird und eine hohe zufällige Übereinstimmung allein durch die Ungleichverteilung der Klassen entstehen könnte. Die Interpretation der Kappa-Werte erfolgte gemäss der Klassifikation von Landis und Koch (1977).

Metriken der Interrater-Reliabilität (KI vs. Mensch)

Um zu beurteilen, wie akkurat die Software im Vergleich zu menschlichen Experten arbeitet, wurden neben Cohen's Kappa folgende diagnostische Gütekriterien berechnet:

Sensitivität (Recall / True Positive Rate):

Diese Metrik gilt als das kritischste Mass im Kontext von Systematic sowie Scoping Reviews. Sie gibt an, wie viel Prozent der tatsächlich relevanten Literatur von der Software korrekt als "relevant" erkannt wurden. Eine hohe Sensitivität ist unabdingbar, um sicherzustellen, dass keine wichtige Literatur übersehen wird.

Spezifität (True Negative Rate):

Sie gibt an, wie gut die Software irrelevante Literatur korrekt aussortiert. Eine hohe Spezifität ist wichtig für die Effizienz des Tools, da sie den Arbeitsaufwand für die Forschenden reduziert, indem sie die Menge der fälschlicherweise als relevant markierten Artikel (False Positives) minimiert.

Genauigkeit (Accuracy):

Dieses Mass beschreibt den Anteil aller korrekten Entscheidungen (sowohl Includes als auch Excludes) an der Gesamtzahl der Entscheidungen. Da Literaturdatensätze oft stark unbalanciert sind (viel mehr irrelevante als relevante Artikel), wurde dieser Wert nur ergänzend betrachtet.

Präzision (Precision):

Die Präzision gibt an, wie viele der von der Software als relevant markierten Artikel tatsächlich relevant waren. Ein niedriger Wert deutet darauf hin, dass der Nutzer viele irrelevante Treffer manuell nachprüfen muss.

F1-Score:

Der F1-Score stellt das harmonische Mittel aus Präzision und Sensitivität dar. Er bietet eine ausgewogene Einzelmetrik, um die Gesamtleistung des Klassifikators zu beurteilen, insbesondere wenn ein Kompromiss zwischen dem Finden aller relevanten Artikel und der Vermeidung von Fehlalarmen gefunden werden muss.

2.2 Durchführung der Usability-Testings

Im Rahmen des SARA-Projekts wurden moderierte Usability-Testings mit drei unterschiedlichen Gruppen durchgeführt. Ziel war es, den ersten lauffähigen Prototypen der Software SARA mit Usergruppen zu testen, um Feedback und Verbesserungsvorschläge zu erhalten.

2.2.1 Teilnehmergruppen

1. **Forscherguppe:** Eine Gruppe von Forschern, die aktuell ein Systematic Review erstellen und mitten im Screening-Prozess sind.
2. **Bibliothekarin:** Eine Bibliothekarin aus der Hochschulbibliothek, welche sich speziell im Bereich KI-Tools bei Literaturrecherchen auskennt.
3. **Hochschulbibliothekarinnen:** Ein Team von Hochschulbibliothekarinnen, die den Service zur Unterstützung beim Screening in Literaturrecherchen an der Hochschule testen und bereits bei einigen Reviews mitgearbeitet haben.

2.2.2 Durchführung und Ergebnisse

Die Usability-Testings wurden in Form von Interviews durchgeführt. Die Teilnehmer erhielten Aufgaben und Fragestellungen, um die Benutzerfreundlichkeit und Funktionalität des Tools zu bewerten. Die Ergebnisse dieser Tests liefern wertvolle Erkenntnisse über die Stärken und Schwächen des Tools aus der Sicht verschiedener Nutzergruppen.

Die Ergebnisse der Usability-Testings werden im Detail präsentiert, um die Erfahrungen und Rückmeldungen der Nutzer zu verdeutlichen und ihre Implikationen für die Weiterentwicklung des Tools aufzuzeigen.

3 Ergebnisse

3.1 Retest-Reliabilität

Die Retest-Reliabilität der Software SARA wurde anhand von zwei unterschiedlichen Datensätzen evaluiert: einem Systematic Review (Projekt DHL) und einem Scoping Review (Projekt DHEM). Für beide Projekte wurden jeweils fünf unabhängige Durchläufe (Runs) durchgeführt und paarweise miteinander verglichen, was insgesamt 10 Vergleichspaare pro Projekt ergab.

3.1.1 Ergebnisse des Systematic Reviews (Projekt DHL)

Der Datensatz des Systematic Reviews umfasste eine Stichprobe von 99 bis 100 Studien (die ersten 100 Studien damals noch laufenden Reviews). Die Analyse der 10 paarweisen Vergleiche zeigte eine ausserordentlich hohe Konsistenz der Softwareentscheidungen.

- **Durchschnittliches Kappa:** Der mittlere Cohen's Kappa-Wert über alle Vergleiche lag bei 0.932. Nach der Klassifikation von Landis und Koch (1977) entspricht dies einer "fast perfekten" Übereinstimmung (*Almost Perfect*).
- **Spannweite:** Die Kappa-Werte variierten zwischen einem Minimum von 0.853 und einem Maximum von 1.000.
- **Übereinstimmung:** In drei der zehn Vergleiche (Run 2 vs. 3, Run 2 vs. 6, Run 3 vs. 6) erreichte die Software eine perfekte Übereinstimmung (Kappa = 1.000). Selbst im "schlechtesten" Fall (Run 1 vs. 4/5) lag die prozentuale Übereinstimmung noch bei sehr hohen 96.97%.

Diese Ergebnisse deuten darauf hin, dass die Software SARA bei klassischen Systematic Reviews mit klar definierten Ein- und Ausschlusskriterien extrem stabile und reproduzierbare Ergebnisse liefert.

3.1.2 Ergebnisse des Scoping Reviews (Projekt DHEM)

Der Datensatz des Scoping Reviews war mit 239 Studien umfangreicher, da dieses Review zum Messzeitpunkt bereits vollständig abgeschlossen war. Scoping Reviews zeichnen sich oft durch breitere und explorativere Fragestellungen aus, was die Klassifikationsaufgabe für eine KI potenziell schwieriger macht.

- **Durchschnittliches Kappa:** Der mittlere Cohen's Kappa-Wert lag hier bei 0.750. Dies entspricht einer "substanziellen" Übereinstimmung (*Substantial*).
- **Spannweite:** Die Werte streuten stärker als beim Systematic Review, mit einem Minimum von 0.647 und einem Maximum von 0.844.
- **Interpretation:** Während zwei Vergleiche (Run 1 vs. 2 und Run 1 vs. 5) noch den Bereich der "fast perfekten" Übereinstimmung erreichten ($\text{Kappa} > 0.81$), fielen die übrigen acht Vergleiche in den Bereich der "substanziellen" Übereinstimmung.

Die etwas niedrigere Konsistenz im Vergleich zum Systematic Review lässt sich vermutlich auf die Natur des Scoping Reviews zurückführen. Die oft weniger scharf abgegrenzten Kriterien bei explorativen Reviews können dazu führen, dass das Sprachmodell bei Grenzfällen ("Borderline Cases") in verschiedenen Durchläufen leicht unterschiedliche Wahrscheinlichkeiten berechnet, was zu variierenden Klassifikationen führt. Dennoch liegt die Reliabilität mit einem Durchschnittswert von knapp 0.75 deutlich im robusten Bereich.

3.1.3 Zusammenfassende Bewertung der Retest-Reliabilität

Insgesamt zeigt die Software SARA eine hohe bis sehr hohe zeitliche Stabilität.

- Bei **Systematic Reviews** (DHL) arbeitet das Tool nahezu deterministisch mit fast perfekter Reproduzierbarkeit ($\emptyset$ Kappa 0.93).
- Bei **Scoping Reviews** (DHEM) ist eine gewisse Varianz zu beobachten, die Ergebnisse bleiben jedoch mit einer substanziellen Übereinstimmung ($\emptyset$ Kappa 0.75) verlässlich.

Diese Ergebnisse bestätigen, dass die Software für den wissenschaftlichen Einsatz geeignet ist, wobei bei explorativen Fragestellungen (Scoping Reviews) empfohlen wird, kritische Ausschlüsse immer durch einen zweiten Durchlauf oder menschliche Kontrolle zu verifizieren.

3.2 Interrater-Reliabilität

Die Validierung der Software SARA gegenüber menschlichen Expertenentscheidungen erfolgte am Datensatz des Systematic Reviews (Projekt DHL). Nach Bereinigung und Matching der Datensätze konnten insgesamt 798 Studien direkt verglichen werden.

3.2.1 Analyse der Kontingenztafel

Die Betrachtung der Konfusionsmatrix offenbart eine starke Asymmetrie in den Entscheidungen der Software:

- **True Negatives (Korrekte Ausschlüsse):** In 763 Fällen waren sich KI und Mensch einig, dass die Studie irrelevant ist.

- **True Positives (Korrekte Einschlüsse):** In lediglich 3 Fällen stimmten KI und Mensch überein, dass die Studie relevant ist.
- **False Positives (Falsche Einschlüsse):** Die Software markierte nur eine einzige Studie (1) als relevant, die von den Menschen ausgeschlossen wurde.
- **False Negatives (Falsche Ausschlüsse):** In 31 Fällen schloss die Software eine Studie aus, die von den menschlichen Experten als relevant (Include) eingestuft wurde.

3.2.2 Statistische Kennwerte

Die berechneten Metriken zeichnen ein differenziertes Bild der aktuellen Leistungsfähigkeit:

- **Genauigkeit (Accuracy):** Mit einem Wert von 95.99% erscheint die Gesamtleistung auf den ersten Blick exzellent. Dieser Wert ist jedoch durch die hohe Anzahl an irrelevanten Studien im Datensatz (Class Imbalance) verzerrt und darf nicht als alleiniges Qualitätsmass herangezogen werden.
- **Spezifität:** Die Software erreichte eine nahezu perfekte Spezifität von 99.87%. Das bedeutet, dass sie irrelevante Literatur extrem zuverlässig erkennt und aussortiert. Es gab fast kein "Rauschen" durch falsche Treffer.
- **Sensitivität (Recall):** Der kritischste Wert für Systematic Reviews fällt mit 8.82% sehr niedrig aus (Poor). Von den insgesamt 34 Studien, die von Menschen als relevant eingestuft wurden (31 False Negatives + 3 True Positives), erkannte die Software lediglich 3.
- **Cohen's Kappa:** Der Kappa-Wert von 0.150 deutet nach Landis und Koch (1977) nur auf eine "geringfügige" (*Slight*) Übereinstimmung hin, die kaum über den Zufall hinausgeht.

3.2.3 Zusammenfassende Bewertung der Interrater-Reliabilität

Die Ergebnisse zeigen, dass die Software in der aktuellen Konfiguration extrem konservativ agiert ("Over-Filtering").

Während die Spezifität exzellent ist – das Tool produziert also kaum Fehlalarme und entlastet Forschende davon, irrelevante Texte zu lesen – ist die Sensitivität jedoch aktuell noch klar unzureichend für den Einsatz als alleiniges Screening-Tool in einem Systematic oder Scoping Review. Die hohe Zahl an *False Negatives* (31 verpasste relevante Studien) stellt ein Risiko für die Vollständigkeit der Literaturrecherche dar.

Das Tool eignet sich in diesem Zustand hervorragend, um irrelevante Literatur sicher zu bestätigen, muss jedoch hinsichtlich der Erkennung relevanter Literatur (Recall) noch deutlich optimiert werden, beispielsweise durch Anpassung der Prompts oder der Entscheidungsschwellenwerte.

3.3 Usability-Testing

Im folgenden werden die Erkenntnisse aus den einzelnen Usertestings vorgestellt.

3.3.1 Usability-Testing mit der Forschungsgruppe

Das Usability-Testing mit der Forschungsgruppe wurde am 25. November 2025 durchgeführt. Die Teilnehmer waren zwei Wissenschaftler*innen, die an einem Literatur-Review zum Thema Digitale Gesundheitskompetenz arbeiteten. Ziel des Tests war es, die Benutzerfreundlichkeit und Funktionalität des Tools zu bewerten.

Die Teilnehmer erhielten eine Datei mit 100 Papers und einen Link zur SARA-Webseite. Während des Tests wurden sie gebeten, laut zu denken und ihre Erfahrungen und Probleme zu äussern. Die Ergebnisse des Tests liefern wertvolle Erkenntnisse über die Stärken und Schwächen des Tools aus der Sicht von Nutzern, die an einem Literatur-Review arbeiten.

Die Teilnehmer fanden das SARA-Tool grundsätzlich benutzerfreundlich, aber es gab einige Probleme und Unklarheiten. Sie hatten Schwierigkeiten, die Inclusion- und Exclusion-Kriterien richtig zu definieren und die Ergebnisse zu interpretieren. Sie bemängelten auch, dass das Tool nicht immer die Sprache erkannte. Die Sprache der Studien wurde vom Forschungsteam nämlich als Ein- und Ausschlusskriterien definiert, was von Seiten KI aber nicht erkannt werden konnte.

Ein wichtiger Aspekt war die Diskussion über die Definition von Inclusion- und Exclusion-Kriterien. Die Teilnehmer hatten Schwierigkeiten, diese Kriterien richtig zu definieren und die Ergebnisse zu interpretieren. Sie schlugen vor, dass das Tool eine bessere Anleitung und Unterstützung für die Definition von Inclusion- und Exclusion-Kriterien bieten sollte.

Ein weiterer wichtiger Aspekt war die Exportfunktion der Software. Die Teilnehmer wünschten sich, dass die Ergebnisse in einem Format exportiert werden können, das direkt in Covidence importiert werden kann. Dies würde den Workflow erleichtern und die Effizienz steigern.

Insgesamt lieferte das Usability-Testing mit der Forschungsgruppe wertvolle Erkenntnisse über die Stärken und Schwächen des Tools.

3.3.2 Usability-Testing mit AI-Expertin

Das Usability-Testing mit der AI-Expertin für Literaturreviews wurde am 8. Dezember 2025 durchgeführt. Die Teilnehmerin war eine Bibliothekarin an der ZHAW-Hochschulbibliothek, die Erfahrung mit Literaturrecherchen und KI-Tools hat.

Die Teilnehmerin wurde gebeten, das Tool zu verwenden, um die Titel, Abstracts und Volltexte von Studien zu screenen. Sie erhielt einen Link zur SARA-Webseite und wurde gebeten, ihren Bildschirm zu teilen und laut zu denken, während sie das Tool verwendete.

Die Teilnehmerin fand die Software grundsätzlich benutzerfreundlich, aber es gab einige Probleme und Unklarheiten. Zu Beginn des Usertestings viel auf, dass das Ziel und der Zweck der Software als «digitaler Assistent» nicht klar ersichtlich waren. Dies führte zu einer erhöhten Skepsis gegenüber der Software.

Sie hatte zudem Schwierigkeiten, die einzelnen Felder wie Objectives sowie die Inclusion- und Exclusion-Kriterien richtig zu definieren.

Ein wichtiger Aspekt war die Diskussion über die Definition von Inclusion- und Exclusion-Kriterien. Sie schlug vor, dass die Software eine bessere Anleitung und Unterstützung für die einzelnen Eingabefelder im Formular haben sollte.

Die Teilnehmerin betonte auch die Bedeutung des Urheberrechts und des Lizenzrechts bei der Verwendung von Volltexten. Sie wies darauf hin, dass die meisten Verlage das Hochladen von Volltexten einschränken und dass es wichtig ist, sicherzustellen, dass die Volltexte nicht in einem LLM in den Trainingsdaten landen.

Die Teilnehmerin fand die Oberfläche des Tools grundsätzlich ansprechend und benutzerfreundlich. Sie schlug vor, das Tool weiter zu verbessern, indem man den Einstieg in die Software mithilfe von klaren Anweisungen, Erklärungen und Hilfetexten optimiert.

Insgesamt lieferte das Usability-Testing mit der AI-Expertin wertvolle Erkenntnisse über die Stärken und Schwächen des Tools.

3.3.3 Usability-Testing mit einer Gruppe von Hochschulbibliothekarinnen

Das Usability-Testing mit der Gruppe der Hochschulbibliothekarinnen wurde am 9. Dezember 2025 durchgeführt. Die Teilnehmerinnen waren drei Bibliothekarinnen an der ZHAW-Hochschulbibliothek, die Erfahrung mit Literaturrecherchen und der Unterstützung von Forschenden bei der Erstellung von Systematic Reviews haben.

Die Teilnehmerinnen wurden gebeten, das SARA-Tool zu verwenden, um die Titel und Abstracts von Studien zu screenen. Sie erhielten einen Link zur SARA-Webseite und wurden gebeten, ihren Bildschirm zu teilen und laut zu denken, während sie das Tool verwendeten.

Die Teilnehmerinnen fanden das SARA-Tool grundsätzlich benutzerfreundlich, aber es gab einige Probleme und Unklarheiten. Auch in diesem Fall war gleich zu Beginn die Frage im Raum, was der Sinn und Zweck dieser Software ist. Das Ziel als «Digitaler Assistent» im Screening-Prozess war für alle nicht klar ersichtlich. Weiter hatten sie Schwierigkeiten, die Objectives sowie die Inclusion- und Exclusion-Kriterien richtig zu definieren.

Ein wichtiger Aspekt war die Diskussion über die Ergebnisse und die Ergebnisdarstellung der Software. Es war unklar, was man im Anschluss mit den Ergebnissen (Liste im CSV-Format) anstellen und im Review-Prozess weiterarbeiten sollte, wenn das Review aus mehrere tausend Artikel beinhalten würden. Es wurde daher vorgeschlagen, eine weitere Seite (View) für die Ergebnisdarstellung zu erstellen, mit welcher man weiterarbeiten könnte. Wünschenswert wäre ihrerseits ebenfalls eine Integration in Covidence oder andere Screening-Tools.

Insgesamt lieferte das Usability-Testing mit der Gruppe der Hochschulbibliothekarinnen wertvolle Erkenntnisse über die Stärken und Schwächen des Tools.

4 Diskussion

Die vorliegende Evaluation der Software SARA liefert ein gemischtes, aber vielversprechendes Bild. Grundsätzlich konnte der Proof of Concept erbracht werden: Die entwickelte Architektur ist technisch in der Lage, bibliografische Daten zu verarbeiten, Inhalte mittels Large Language Models (LLMs) zu analysieren und Klassifikationsentscheidungen zu treffen. Die hohe Retest-Reliabilität, insbesondere bei Systematic Reviews (Kappa > 0.9), zeigt zudem, dass das System kein "Zufallsgenerator" ist, sondern konsistente und reproduzierbare Entscheidungen trifft.

Dennoch offenbaren die Ergebnisse deutliche Limitationen, die einen Einsatz in der produktiven Forschungspraxis zum aktuellen Zeitpunkt noch einschränken.

4.1 Herausforderung Sensitivität

Das kritischste Ergebnis der quantitativen Analyse ist die unzureichende Sensitivität (Recall) von unter 10%. Die Software agiert momentan zu restriktiv ("Over-Filtering"). Während sie irrelevante Literatur mit fast perfekter Präzision aussortiert (hohe Spezifität), übersieht sie einen Grossteil der relevanten Studien. Für die Erstellung von Systematic Reviews, bei denen Vollständigkeit das oberste Gebot ist, stellt dies ein erhebliches Risiko dar. Die KI "versteh" die Ausschlusskriterien zwar, wendet sie aber vermutlich zu streng an oder gewichtet Nuancen in Abstracts anders als menschliche Experten.

4.2 Technische Stabilität und Usability

Neben der algorithmischen Leistung zeigten die Usertestings, dass auch auf der Anwendungsebene Handlungsbedarf besteht.

- **Software-Bugs:** Es traten im Testbetrieb noch technische Fehler auf, die den Workflow unterbrechen können oder sich in den Ergebnissen bemerkbar machen.
- **User Interface (UI):** Die Rückmeldungen der Testnutzer deuten darauf hin, dass die Bedienung noch nicht intuitiv genug ist.
- **Ergebnisdarstellung:** Die Art und Weise, wie die Entscheidungen präsentiert werden, entspricht noch nicht den Bedürfnissen der unterschiedlichen Usergruppen.

4.3 Diskussion der Implikationen der Ergebnisse aus den Usability Testings

Die Ergebnisse der drei Usability-Testings mit der Forschungsgruppe, der AI-Expertin und der Gruppe der Hochschulbibliothekar*innen liefern wertvolle Erkenntnisse über die Stärken und Schwächen des Tools. Die Teilnehmerinnen und Teilnehmer fanden das Tool grundsätzlich benutzerfreundlich, aber es gab einige Probleme und Unklarheiten.

Ein wichtiger Aspekt war die Diskussion über die Definition von Inclusion- und Exclusion-Kriterien, welcher in allen drei Usability-Testings zu Wort kam. Die Teilnehmerinnen und Teilnehmer hatten Schwierigkeiten, diese Kriterien richtig zu definieren und auch die Felder im Formular entsprechend auszufüllen. Sie schlugen vor, dass das SARA-Tool eine bessere Anleitung und Unterstützung für die Definition bieten sollte. Grundsätzlich sollte die Software transparenter werden, indem es im einleitenden Text (nach dem Login) das Ziel und den Zweck klar kommuniziert.

Die Teilnehmerinnen und Teilnehmer betonten auch die Bedeutung des Urheberrechts und des Lizenzrechts bei der Verwendung von Volltexten. Sie wiesen darauf hin, dass die meisten Verlage das Hochladen von Volltexten einschränken und dass es wichtig ist, sicherzustellen, dass die Volltexte nicht in einem LLM in den Trainingsdaten landen. Dies war unter anderem ein wesentlicher Grund, warum die Funktionalität des Fulltext-Screenings nicht implementiert wurde.

Alle Teilnehmerinnen und Teilnehmer aus den Usability-Testings erwähnte das Thema mit der unzureichenden Darstellung der Ergebnisse. Ein Export einer Liste mit allen Entscheidungen im CSV-Format wurde als nicht geeignet empfunden.

Die Ergebnisse der Usability-Testings zeigen, dass die Software das Potenzial hat, den Prozess des Literaturreviews zu automatisieren und die Effizienz zu steigern, sofern der Nutzen klar und das Vertrauen der User*innen da ist. Es bedarf jedoch weiterer Entwicklung und Verbesserung, um es zu einem effektiven Werkzeug für Literaturreviews zu machen.

5 Ausblick

Obwohl die Grundidee von SARA funktioniert, ist weitere Entwicklungsarbeit notwendig, um das Tool von einem funktionierenden Prototypen zu einem verlässlichen Forschungsassistenten zu entwickeln. Die nächsten Arbeitsschritte sollten sich auf folgende Schwerpunkte konzentrieren:

1. **Optimierung der Genauigkeit (Prompt Engineering):**

Um die Sensitivität zu erhöhen, müssen die System-Prompts überarbeitet werden. Das Ziel muss sein, die KI "defensiver" zu instruieren: Im Zweifel sollte eine Studie eher eingeschlossen (Include) als ausgeschlossen werden. Auch Techniken wie *Few-Shot Prompting* (das Bereitstellen von Beispielen im Prompt) könnten helfen, das Verständnis der KI für komplexe Einschlusskriterien zu schärfen.

2. **Verbesserung der User Experience (UX/UI):**

Basierend auf dem Feedback aus den Usertestings sollte die Benutzeroberfläche überarbeitet werden. Ein Fokus sollte auf der Hilfestellung des Eingabefelds sowie auf der Ergebnisdarstellung liegen.

3. **Technische Stabilisierung:**

Die identifizierten Software-Bugs müssen behoben werden, um einen reibungslosen Ablauf auch bei grossen Datensätzen zu gewährleisten.

Zusammenfassend lässt sich sagen: SARA hat das Potenzial, den Prozess der Literaturrecherche signifikant zu beschleunigen, insbesondere durch die effiziente Eliminierung irrelevanter Studien. Wenn es in zukünftigen Iterationen gelingt, die Sensitivität auf ein akzeptables Niveau zu heben und die Usability zu verfeinern, kann die Software zu einem wertvollen Werkzeug für die wissenschaftliche Community werden.

6 Literaturverzeichnis

- Cao, C., Sang, J., Arora, R., Kloosterman, R., Cecere, M., Gorla, J., Saleh, R., Chen, D., Drennan, I., Teja, B., Fehlings, M., Ronksley, P., Leung, A. A., Weisz, D. E., Ware, H., Whelan, M., Emerson, D. B., Arora, R., & Bobrovitz, N. (2024). *Prompting is all you need: LLMs for systematic review screening*. <https://doi.org/10.1101/2024.06.01.24308323>
- Landis, J. R., & Koch, G. G. (1977). The Measurement of Observer Agreement for Categorical Data. *Biometrics*, 33(1), 159. <https://doi.org/10.2307/2529310>